

**Disciplina:** Modelos Lineares Generalizados

**Curso:** Graduação em Estatística

**Código:** EST0011

**Semestre:** 2023.2

**Prof.** Frederico Machado Almeida

## Lista de Exercícios #4

### Observações:

- Questões para entregar: 1, 2(b,c), 3 e 4.
- Demais questões são apenas para estudar.
- Prazo de entrega: **17/11/2023**

**Q01.** Suponha que  $Y_i \sim \exp(\phi)$ , para  $i = 1, \dots, 5$ . Isto é,

$$f(y_i|\phi) = \frac{1}{\phi} \exp\left(-\frac{y_i}{\phi}\right), \text{ com } y_i > 0 \text{ e } \phi > 0.$$

Suponha que o vetor observado foi  $\mathbf{y} = (2.8, 3.5, 2.4, 1.9, 3.0)^\top$  com média  $\bar{y} = 2.72$ .

- Implemente manualmente o algoritmo de Newton-Raphson e itere até obter a convergência. Feito isso, apresente uma tabela contendo as iterações, as estimativas (para cada iteração), e a tolerância.
- Como o valor obtido se compara com o estimador de máxima verossimilhança? Isto é,  $\hat{\phi} = \bar{y}$ ?

**Q02.** Assuma que  $y_1, y_2, \dots, y_n$  é uma amostra observada de  $Y$ . Para cada distribuição abaixo, apresente a função desvio escalonado total.

- Distribuição Weibull:  $f(y_i|\alpha, \beta) = \frac{\alpha}{\beta} \left(\frac{y_i}{\beta}\right)^{\alpha-1} \exp\left[-\left(\frac{y_i}{\beta}\right)^\alpha\right]$ , com  $y_i > 0$ ;  $\alpha, \beta > 0$ .
- Distribuição Binomial:  $Y_i \sim \text{Binom}(n_i, p_i)$   $P(Y_i = y_i|\alpha, \beta) = \binom{n_i}{y_i} p_i^{y_i} (1 - p_i)^{n_i - y_i}$ , com  $y_i = 0, 1, 2, \dots, n_i$  e  $0 < p_i < 1$ .
- Distribuição Beta:  $f(y_i|\alpha, \beta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} y_i^{\alpha-1} (1 - y_i)^{\beta-1}$ , com  $0 < y_i < 1$ , e  $\Gamma(\cdot)$  denota a função gama.

**Q03.** Considere a função gama apresentada na questão anterior. Conforme mostrado na **Lista 3**, a distribuição gama é membro da família exponencial com ligação canônica. Usando a função de ligação logarítmica (frequentemente usada como função de ligação canônica para a distribuição Poisson), obtenha:

- A função escore  $U(\beta_j)$  e as entradas genéricas  $(j, s)$  da matriz de informação de Fisher, digamos  $\mathcal{I}_{js}(\beta)$ .

- (b) A matriz dos pesos  $W(\beta)$  e a matriz  $G(\beta) = \text{diagonal} \{g'(\mu_i), \text{ com } i = 1, \dots, n\}$ .
- (c) A variável dependente ajustada na  $t$ -ésima iteração do Fisher Scoring, i.e.,  $z_i^{(t)}$ .

**Q04.** Os dados apresentados na Tabela são referentes ao tempo até a morte  $y_i$  (em semanas) de dezassete pacientes que sofrem de leucemia, e  $x_i$  denota a contagem inicial dos glóbulos brancos, em uma escala de  $\log_{10}$ .

$i$	$y_i$	$x_i$	$i$	$y_i$	$x_i$
1	65	3,36	10	143	3,85
2	156	2,88	11	56	3,97
3	100	3,63	12	26	4,51
4	134	3,41	13	22	4,54
5	16	3,78	14	01	5,00
6	108	4,02	15	01	5,00
7	121	4,00	16	05	4,72
8	04	4,23	17	65	5,00
9	39	3,73			

- (a) Obtenha o gráfico de dispersão de  $y_i$  contra  $x_i$ . O diagrama apresenta alguma tendência?
- (b) Uma possível especificação para  $\mu_i = \mathbb{E}(Y_i)$  é,

$$\mathbb{E}(Y_i) = \exp(\beta_0 + \beta_1 x_i). \quad (1)$$

Como pode ser visto, esta especificação permite que  $\mathbb{E}(Y_i)$  seja sempre positivo para todo  $\beta_j$ , com  $j = 0, 1$  e todo  $x_i$ . Qual função de ligação seria apropriada para este caso? Justifique a sua resposta.

- (c) A distribuição Exponencial tem sido frequentemente usada para modelar tempos de sobrevivência. Sua fdp é dada por:  $f(y_i; \mu) = \frac{1}{\mu} \exp\left(-\frac{y_i}{\mu}\right)$ . Observe que, esta distribuição é um caso particular da distribuição Gama (veja Q01-(e), Lista 3), com  $\nu = 1$ . Mostre que  $\mathbb{E}(Y_i) = \mu_i$  e  $\text{Var}(Y_i) = \mu_i^2$ .
- (d) Usando algum software estatístico, ajuste o modelo de regressão, assumindo que os dados seguem uma distribuição Exponencial, com  $\mathbb{E}(Y_i)$  dada segundo a equação (1).
- (e) Para o modelo obtido em (d): (i) compare os valores observados:  $y_i$  e os estimados  $\hat{y}_i = \exp(\hat{\beta}_0 + \hat{\beta}_1 x_i)$ ; (ii) use os resíduos padronizados  $r_i = \frac{y_i - \hat{y}_i}{\hat{y}_i}$  para avaliar a qualidade de ajuste do modelo.
- (f) Interprete os valores dos coeficientes de regressão,  $\hat{\beta}_0$  e  $\hat{\beta}_1$ .

**Q05.** Sabe-se que a concentração de colesterol no soro sanguíneo aumenta com a idade, mas é menos claro se o nível de colesterol também está associado ao peso corporal. As variáveis de interesse são: o nível de colesterol sérico de trinta e dois pacientes (milhões de moles por litro), idade (anos) e o índice de massa corporal (peso dividido pela altura ao quadrado, onde o peso foi medido em quilogramas e a altura em metros). Com base no banco de dados descrito, foi ajustado o modelo de regressão Gama, com função de ligação inversa (por default). Toda informação sobre o ajuste do modelo está apresentada no Apêndice.

**Q02.** Assuma que  $y_1, y_2, \dots, y_n$  é uma amostra observada de  $Y$ . Para cada distribuição abaixo, apresente a função desvio escalonado total.

(b) Distribuição Binomial:  $Y_i \sim \text{Binom}(n_i, p_i)$   $P(Y_i = y_i | \alpha, \beta) = \binom{n_i}{y_i} p_i^{y_i} (1 - p_i)^{n_i - y_i}$ , com  $y_i = 0, 1, 2, \dots, n_i$  e  $0 < p_i < 1$ .

(c) Distribuição Beta:  $f(y_i | \alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} y_i^{\alpha-1} (1 - y_i)^{\beta-1}$ , com  $0 < y_i < 1$ , e  $\Gamma(\cdot)$  denota a função gama.

(b) Distribuição Binomial:  $Y_i \sim \text{Binom}(n_i, p_i)$   $P(Y_i = y_i | \alpha, \beta) = \binom{n_i}{y_i} p_i^{y_i} (1 - p_i)^{n_i - y_i}$ , com  $y_i = 0, 1, 2, \dots, n_i$  e  $0 < p_i < 1$ .

Definindo a log-verossimilhança:

$$L(\beta; y) = \sum_{i=1}^N \left[ y_i \log p_i - y_i \log(1 - p_i) + n_i \log(1 - p_i) + \log \binom{n_i}{y_i} \right]$$

Como para o modelo saturado temos que todos os  $p_i$ 's são distintos e o MLE é  $\hat{p}_i = y_i/n_i$ , o valor máximo da log-verossimilhança será:

$$L(b_{\max}; y) = \sum_{i=1}^N \left[ y_i \log(y_i/n_i) - y_i \log(\frac{n_i - y_i}{n_i}) + n_i \log(\frac{n_i - y_i}{n_i}) + \log \binom{n_i}{y_i} \right]$$

$\forall p < N$  parâmetros, seja  $\hat{p}_i$  os MLE's das probabilidades estimadas e  $\hat{y}_i = n_i \hat{p}_i$  os valores ajustados. Logo, a log-verossimilhança avaliada nesses valores será:

$$L(b; y) = \sum_{i=1}^N \left[ y_i \log(\hat{y}_i/n_i) - y_i \log(\frac{n_i - \hat{y}_i}{n_i}) + n_i \log(\frac{n_i - \hat{y}_i}{n_i}) + \log \binom{n_i}{y_i} \right]$$

Logo a função desvio será:  $D = 2 [L(b_{\max}, y) - L(b, y)]$

$$D = \sum_{i=1}^N \left[ y_i \log\left(\frac{y_i}{\hat{y}_i}\right) + (n_i - y_i) \log\left(\frac{n_i - y_i}{n_i - \hat{y}_i}\right) \right]$$

Como o desvio escalonado é dado como função do desvio:

$D^* = \phi \cdot D$  ; onde  $\phi = \hat{\phi} = 1$  para o modelo binomial, temos

$$\text{que } D^* = D = \sum_{i=1}^N \left[ y_i \log \left( \frac{y_i}{\hat{y}_i} \right) + (n_i - y_i) \log \left( \frac{n_i - y_i}{n_i - \hat{y}_i} \right) \right]$$

(c) Distribuição Beta:  $f(y_i|\alpha, \beta) = \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} y_i^{\alpha-1} (1-y_i)^{\beta-1}$ , com  $0 < y_i < 1$ , e  $\Gamma(\cdot)$  denota a função gama.

Reparametrizando utilizando a média e a dispersão:  $\mu = \frac{\alpha}{\alpha+\beta}$  ,  $\phi = \alpha+\beta$

$\rightarrow \mu = \frac{\alpha}{\phi} \rightarrow \alpha = \mu \cdot \phi$  ;  $\beta = \phi - \alpha = \phi(1-\mu)$  , temos

que  $E(y) = \frac{\alpha}{\alpha+\beta} = \mu$  ;  $\text{Var}(\mu) = \frac{V(\mu)}{1+\phi}$  ; logo:  $\phi = \frac{\mu(1-\mu)-1}{\text{Var}(y)}$

onde  $V(\mu) = \mu(1-\mu)$  , onde  $\mu$  é a resposta média e  $\phi$  pode ser interpretado como o parâmetro de precisão no sentido de que, para  $\mu$  fixo,  $\phi \uparrow \rightarrow \text{Var}(y) \downarrow$ . Reescrevemos a densidade como:

$$f(y; \mu, \phi) = \frac{\Gamma(\phi)}{\Gamma(\mu\phi) \Gamma((1-\mu)\phi)} y^{\mu\phi-1} (1-y)^{(1-\mu)\phi-1} , \quad 0 < y < 1$$

Estabelecendo  $\mu_x$  e  $\phi$  desconhecida o modelo será obtido assumindo que  $y_x$  é escrito da forma:

$g(\mu_x) = \sum_{i=1}^K x_{xi} \beta_i = \eta_x$ , onde  $(\beta_1, \dots, \beta_K)^T$  é o vetor de regressores desconhecidos ( $\beta \in \mathbb{R}^K$ ) e  $(x_{x1}, \dots, x_{xK})$  as observações em  $k$  covariáveis ( $k < n$ )

definindo a linking function  $g(\cdot)$  como a logit-link, temos:

$$\mu_z = \frac{e^{X_z^T \beta}}{1 + e^{X_z^T \beta}} ; \text{ onde } X_z^T = (x_{z1}, \dots, x_{zk}) ; z=1, \dots, n$$

A log-verossimilhança será:

$$L(\beta, \phi) = \sum_{i=1}^n L_z(\mu_z, \phi) \quad \rightarrow \text{equação 1}$$

$$\text{onde } L_z(\mu_z, \phi) = \log \Gamma(\phi) - \log \Gamma(\mu_z \phi) - \log \Gamma((1-\mu_z)\phi) + (\mu_z \phi - 1) \log y_z + \{ (1-\mu_z)\phi - 1 \} \log(1-y_z)$$

$$\text{Como } D(y; \mu, \phi) = \sum_{i=1}^n 2 \cdot (L_z(\tilde{\mu}_z, \phi) - L_z(\mu_z, \phi)) ; \text{ onde } \tilde{\mu}_z \text{ é o valor de } \mu_z \text{ que satisfaz } \frac{\partial L_z}{\partial \mu_z} = 0 \rightarrow \phi(y_z^* - \mu_z^*) = 0 \text{ para } \phi \rightarrow \infty \text{ temos}$$

$$\mu_z^* = \log \left\{ \frac{\mu_z}{(1-\mu_z)} \right\} \text{ e segue que : } \tilde{\mu}_z = y_z ; \text{ logo:}$$

$$\begin{aligned} D(y; \mu, \phi) &= \log \Gamma(\phi) - \log \Gamma(y_z \phi) - \log \Gamma((1-y_z)\phi) \\ &+ (y_z \phi - 1) \log y_z + \{ (1-y_z)\phi - 1 \} \log(1-y_z) \\ &- \left\{ \log \Gamma(\phi) - \log \Gamma(\mu_z \phi) - \log \Gamma((1-\mu_z)\phi) \right. \\ &\quad \left. + (\mu_z \phi - 1) \log y_z + \{ (1-\mu_z)\phi - 1 \} \log(1-y_z) \right\} \end{aligned}$$

$$\begin{aligned} D &= \log \Gamma \left( \frac{\mu_z}{y_z} \right) + \log \Gamma \left( \frac{1-\mu_z}{1-y_z} \right) + \log(y_z) \{ \phi(y_z - \mu_z) \} \\ &+ \log(1-y_z) \{ \phi(\mu_z - y_z) \} \end{aligned}$$

Como  $D^* = \hat{J} \cdot D$

para obtermos  $\hat{J}$  temos que satisfazer:  $U_{\phi}(\beta, \phi) = 0$ , para isso definimos a matriz informação de Fisher:

$$\frac{\partial \mathcal{L}(\beta, \phi)}{\partial \beta_j} = \sum_{t=1}^n \frac{\partial \mathcal{L}_t(\mu_t, \phi)}{\partial \mu_t} \frac{\partial \mu_t}{\partial \eta_t} \frac{\partial \eta_t}{\partial \beta_j}$$

Como  $\frac{d \mu_t}{d \eta_t} = \frac{1}{g'(\mu_t)}$

$$\frac{\partial \mathcal{L}_t(\mu_t, \phi)}{\partial \mu_t} = \phi \left[ \log \frac{y_t}{1-y_t} - \{ \psi(\mu_t \phi) - \psi((1-\mu_t)\phi) \} \right]$$

onde  $\psi(\cdot)$  caracteriza a função digamma i.e.  $\psi(z) = \frac{d}{dz} \log(\Gamma(z))$   
 $\forall z > 0$ , dadas as condições de regularidade, sabe-se que o valor esperado da derivada da equação 1. é zero:

$$\frac{\partial \mathcal{L}(\beta, \phi)}{\partial \beta_j} = \phi \sum_{t=1}^n (y_t^* - \mu_t^*) \frac{1}{g'(\mu_t)} x_{t,j}$$

onde  $y_t^* = \log \left\{ \frac{\mu_t}{(1-\mu_t)} \right\}$  e  $\mu_t^* = \psi(\mu_t \phi) - \psi((1-\mu_t)\phi)$

percebe-se de imediato que  $\hat{J}$  é invariável pela presença da função digamma, tornando desnecessários os demais cálculos das posteriores derivadas parciais. Logo, a título de simplificação:  $D^* = (U_{\phi}(\beta, \phi) = 0) \cdot D$

**Q03.** Considere a função gama apresentada na questão anterior. Conforme mostrado na **Lista 3**, a distribuição gama é membro da família exponencial com ligação canônica. Usando a função de ligação logarítmica (frequentemente usada como função de ligação canônica para a distribuição Poisson), obtenha:

- (a) A função escore  $U(\beta_j)$  e as entradas genéricas  $(j, s)$  da matriz de informação de Fisher, digamos  $\mathcal{I}_{js}(\beta)$ .

$$f(y|\alpha, \beta) = \frac{1}{\beta^\alpha \Gamma(\alpha)} y^{\alpha-1} e^{-y/\beta}$$

$$l(y|\alpha, \beta) = -\frac{y}{\beta} - \alpha \log \beta + (\alpha-1) \log y - \log \Gamma(\alpha)$$

Com parâmetro canônico  $\theta = -\beta^{-1} = \eta$

$$\left\{ \begin{array}{l} \frac{d}{d\theta} \alpha \log\left(-\frac{1}{\theta}\right) = -\frac{\alpha}{\theta} = \frac{-\alpha}{-\frac{1}{\beta}} \longrightarrow \mu = \alpha\beta \\ \frac{d}{d\theta} -\frac{\alpha}{\theta} = \alpha\left(-\frac{1}{\theta^2}\right) = \frac{\alpha}{\theta^2} \longrightarrow V(\mu) = -\alpha\beta^2 \Rightarrow \text{Var}(y) = (-1)(-\alpha\beta^2) = \alpha\beta^2 \\ a(\phi) = -1 \end{array} \right.$$

a) O vetor score  $U(\beta) = \nabla_{\beta} l(\beta, \phi)$  é obtido portanto:

$$\begin{aligned} \frac{\partial l(\beta, \phi)}{\partial \beta_j} &= \sum_{i=1}^n \frac{y_i - \mu_i}{a(\phi)} w_i(\beta) \left( \frac{\partial \eta_i}{\partial \mu_i} \right) x_{ij} \\ &= \sum_{i=1}^n (y_i - \alpha\beta) w_i(\beta) \cdot \alpha\beta^2 \cdot x_{ij} \end{aligned}$$

(b) A matriz dos pesos  $W(\beta)$  e a matriz  $G(\beta) = \text{diagonal} \{g'(\mu_i), \text{ com } i = 1, \dots, n\}$ .

$$b) W(\beta) = \text{diag} \{w_i(\beta), i=1, \dots, n\} \text{ e}$$

$$w_i(\beta) = V^{-1}(\mu_i) \left( \frac{\partial \mu_i}{\partial \eta_i} \right)^2 = -\frac{1}{\alpha\beta^2} (-\alpha\beta^2)^2 = -\alpha\beta^2$$

$$G(\beta) = \text{diag}\{g'(\mu_i), i=1, \dots, n\} = \text{diag}\left\{\frac{\partial u_i}{\partial \mu_i}, i=1, \dots, n\right\}$$

$$= \text{diag}\{-\alpha \beta^2\}_n$$

$$c) \tilde{z}^{(t)} = \tilde{\eta}^{(t)} + G(\tilde{\beta}^{(t)}) (y - \mu^{(t)})$$

$$z_i^{(t)} = \left(-\frac{1}{\beta}\right)^{(t)} + (-\alpha \beta^2)^{(t)} (y - (\alpha \beta)^{(t)})$$



(c) A variável dependente ajustada na  $t$ -ésima iteração do Fisher Scoring, i.e.,  $z_i^{(t)}$ .

Como temos:

$$z_i^{(t)} = \eta_i^{(t)} + (y_i - \mu_i^{(t)}) \frac{1}{V(\mu_i^{(t)}) [g'(\mu_i^{(t)})]^2}$$

como,  $\mu_i = \log(e^{x^T \beta})$  e

$$g(\mu_i) = \sum_{k=1}^m x_{ik} \beta_k = \eta_i \longrightarrow \eta_i^{(t)} = x_{ik} \beta_k$$

$$\text{com } [g'(\mu_i^{(t)})]^{-2} = \frac{1}{(\mu_i^{(t)})^2}; \quad V(\mu_i^{(t)})^{-2} = -(\alpha \cdot \beta_k)^{-2}$$

logo:

$$z_i^{(t)} = x_{ik} \beta_k - (y_i - \mu_i^{(t)}) \cdot (\alpha \cdot \beta_k)^{-2} \cdot (\mu_i^{(t)})^{-2}$$