

Lista 2

Modelos Lineares Generalizados - 2/2023

César Augusto Galvão - 19/0011572

Laiza Mendes - 20/0067028

Table of contents

Questão 1	2
a) Proponha algum método para resolver o problema da multicolinearidade no conjunto de dados	2
b) Usando algum método de seleção de variáveis, obtenha o modelo final para o conjunto de dados	2
c) Apresente a tabela de Análise de Variância para testar a significância global dos coeficientes do modelo final. Apresente as hipóteses de teste e conclua.	2
d) Com base no modelo obtido no item anterior, faça uma análise de resíduos e conclua.	2
Questão 2	2
a) Ajuste um modelo de regressão linear e interprete os resultados obtidos	3
b) Obtenha a tabela ANOVA para o modelo obtido no item (a) e interprete os resultados	4
c) Considere a possibilidade de incluir a interação entre as variáveis independentes .	4
Apêndice	6

Questão 1

Considere os dados sobre a qualidade do vinho tinto, apresentados no ficheiro `Q01-data.txt`. Ajuste o modelo de regressão linear múltipla, e faça uma análise completa desses dados. Que conclusões você tira dessa análise? (use 5% de significância durante as análises).

- a) **Proponha algum método para resolver o problema da multicolinearidade no conjunto de dados**
- b) **Usando algum método de seleção de variáveis, obtenha o modelo final para o conjunto de dados**
- c) **Apresente a tabela de Análise de Variância para testar a significância global dos coeficientes do modelo final. Apresente as hipóteses de teste e conclua.**
- d) **Com base no modelo obtido no item anterior, faça uma análise de resíduos e conclua.**

Questão 2

Uma equipe de pesquisadores de saúde mental deseja comparar três métodos de tratamento da depressão grave (A, B e C=referência). Eles também gostariam de estudar a relação entre idade e eficácia do tratamento, bem como a interação (se houver) entre idade e tratamento. Cada elemento da amostra aleatória simples de 36 pacientes, foi selecionado aleatoriamente para receber o tratamento A, B ou C. Os dados obtidos podem ser encontrados no ficheiro `Q02-data.txt`. A variável dependente y é a eficácia do tratamento; as variáveis independentes são: a idade do paciente no aniversário mais próximo e o tipo de tratamento administrado (use 1% de significância durante as análises).

Uma amostra dos dados é exibida na tabela a seguir:

eficacia	idade	tratamento
56	21	A
41	23	B
40	30	B
28	19	C
55	28	A
25	23	C

a) Ajuste um modelo de regressão linear e interprete os resultados obtidos

Temos um potencial modelo de regressão linear que pode ou não conter interações entre as variáveis, o qual pode ser expresso em sua forma saturada, em que X_1 é a variável idade e X_2 a variável tratamento

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{1i} x_{2i} + \varepsilon_i, \quad i = 1, 2, \dots, n \quad (1)$$

ou, de forma análoga, desmembrando X_2 em variáveis *dummy* X_A e X_B , indicadores da presença do tratamento A e B , ambas assumindo valor 0 quando se trata do tratamento C

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{Ai} + \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i. \quad (2)$$

Se simplesmente ajustamos um modelo de regressão linear – sem os termos de interação – utilizando (2) como referência na função `lm()`, obtemos os seguintes resultados:

Coefficiente	Estimativa	EP	Estatística t	p-valor
(Intercept)	22.291	3.505	6.359	0.000
idade	0.664	0.070	9.522	0.000
A	10.253	2.465	4.159	0.000
B	0.445	2.464	0.181	0.858

Ou seja, se considerarmos independentemente idade, tratamento A e tratamento B, podemos considerar que:

- Há uma linha de base na eficácia de aproximadamente 22.3, i.e. sob o tratamento C;
- A eficácia base para o tratamento A é de 32.3;
- A eficácia base para o tratamento B é de 22.75 – mas poderíamos desconsiderar este coeficiente, se nos guiarmos pelo p-valor;
- Cada ano a mais de vida incrementa a eficácia em 0.644.

É possível considerar que um tamanho de amostra pequeno tenha grande influência sobre a significância de $\beta_3 = 0$ do modelo. No entanto, trata-se de um fenômeno para o qual o tratamento pode estar estreitamente associado à idade, caso em que teríamos que considerar o modelo (2) por completo.

b) Obtenha a tabela ANOVA para o modelo obtido no item (a) e interprete os resultado

c) Considere a possibilidade de incluir a interação entre as variáveis independentes

Supõe-se que $\varepsilon_i \sim N(0, \sigma^2)$.

i) Lista de todos os submodelos possíveis

A partir do modelo (2), construímos todos os possíveis submodelos. Considerando que temos três covariáveis e dois termos de interação, temos $\sum_{n=1}^5 \binom{6}{n} = 62$ modelos

1. $y_i = \beta_0 + \varepsilon_i$
2. $y_i = \beta_1 x_{1i} + \varepsilon_i$
3. $y_i = \beta_2 x_{Ai} + \varepsilon_i$
4. $y_i = \beta_3 x_{Bi} + \varepsilon_i$
5. $y_i = \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
6. $y_i = \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
7. $y_i = \beta_0 + \beta_1 x_{1i} + \varepsilon_i$
8. $y_i = \beta_0 + \beta_2 x_{Ai} + \varepsilon_i$
9. $y_i = \beta_0 + \beta_3 x_{Bi} + \varepsilon_i$
10. $y_i = \beta_0 + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
11. $y_i = \beta_0 + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
12. $y_i = \beta_1 x_{1i} + \beta_2 x_{Ai} + \varepsilon_i$
13. $y_i = \beta_1 x_{1i} + \beta_3 x_{Bi} + \varepsilon_i$
14. $y_i = \beta_1 x_{1i} + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
15. $y_i = \beta_1 x_{1i} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
16. $y_i = \beta_2 x_{Ai} + \beta_3 x_{Bi} + \varepsilon_i$
17. $y_i = \beta_2 x_{Ai} + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
18. $y_i = \beta_2 x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
19. $y_i = \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
20. $y_i = \beta_3 x_{Bi} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$

21. $y_i = \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
22. $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{Ai} + \varepsilon_i$
23. $y_i = \beta_0 + \beta_1 x_{1i} + \beta_3 x_{Bi} + \varepsilon_i$
24. $y_i = \beta_0 + \beta_1 x_{1i} + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
25. $y_i = \beta_0 + \beta_1 x_{1i} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
26. $y_i = \beta_0 + \beta_2 x_{Ai} + \beta_3 x_{Bi} + \varepsilon_i$
27. $y_i = \beta_0 + \beta_2 x_{Ai} + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
28. $y_i = \beta_0 + \beta_2 x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
29. $y_i = \beta_0 + \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
30. $y_i = \beta_0 + \beta_3 x_{Bi} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
31. $y_i = \beta_0 + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
32. $y_i = \beta_1 x_{1i} + \beta_2 x_{Ai} + \beta_3 x_{Bi} + \varepsilon_i$
33. $y_i = \beta_1 x_{1i} + \beta_2 x_{Ai} + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
34. $y_i = \beta_1 x_{1i} + \beta_2 x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
35. $y_i = \beta_1 x_{1i} + \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
36. $y_i = \beta_1 x_{1i} + \beta_3 x_{Bi} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
37. $y_i = \beta_1 x_{1i} + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
38. $y_i = \beta_2 x_{Ai} + \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
39. $y_i = \beta_2 x_{Ai} + \beta_3 x_{Bi} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
40. $y_i = \beta_2 x_{Ai} + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
41. $y_i = \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
42. $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{Ai} + \beta_3 x_{Bi} + \varepsilon_i$
43. $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{Ai} + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
44. $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
45. $y_i = \beta_0 + \beta_1 x_{1i} + \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
46. $y_i = \beta_0 + \beta_1 x_{1i} + \beta_3 x_{Bi} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
47. $y_i = \beta_0 + \beta_1 x_{1i} + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
48. $y_i = \beta_0 + \beta_2 x_{Ai} + \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
49. $y_i = \beta_0 + \beta_2 x_{Ai} + \beta_3 x_{Bi} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$

50. $y_i = \beta_0 + \beta_2 x_{Ai} + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
51. $y_i = \beta_0 + \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
52. $y_i = \beta_1 x_{1i} + \beta_2 x_{Ai} + \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$
53. $y_i = \beta_1 x_{1i} + \beta_2 x_{Ai} + \beta_3 x_{Bi} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
54. $y_i = \beta_1 x_{1i} + \beta_2 x_{Ai} + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
55. $y_i = \beta_1 x_{1i} + \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
56. $y_i = \beta_2 x_{Ai} + \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
57. $y_i = \beta_1 x_{1i} + \beta_2 x_{Ai} + \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
58. $y_i = \beta_0 + \beta_2 x_{Ai} + \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
59. $y_i = \beta_0 + \beta_1 x_{1i} + \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
60. $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{Ai} + \beta_4 x_{1i} x_{Ai} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
61. $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{Ai} + \beta_3 x_{Bi} + \beta_5 x_{1i} x_{Bi} + \varepsilon_i$
62. $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{Ai} + \beta_3 x_{Bi} + \beta_4 x_{1i} x_{Ai} + \varepsilon_i$

ii) Interpretação de coeficientes de regressão de fatores de interação

iii) tabela ANOVA

iv) Análise completa dos resíduos do modelo

Apêndice

Todo o projeto de composição deste documento pode ser encontrado aqui: <https://github.com/cesar-galvao/mlg>